

Tài liệu Cấu trúc Kho Dữ liệu Google Drive

Ngô Tấn Đạt

23/05/2026

Mục tiêu

Tài liệu này mô tả cấu trúc thư mục lưu trữ dữ liệu trên Google Drive cho dự án dự báo sản lượng điện mặt trời. Toàn bộ dữ liệu được tổ chức theo từng tầng xử lý rõ ràng, từ dữ liệu thô ban đầu đến dữ liệu đã qua ETL, kèm theo tài liệu mô tả schema và nguồn gốc.

1 Cấu trúc thư mục

```
Google Drive/  
|-- Du_An_Tot_Nghiep/  
    |-- raw/  
        |-- NASA_Solar_Data_Collected.csv  
        |-- VN_Solar_NASA_Data_All_Provinces.csv  
    |-- processed/  
    |-- etl/  
    |-- doc/  
        |-- schema/  
        |-- source_description/  
        |-- data_dictionary/
```

2 Thư mục raw/

Chứa dữ liệu thô được crawl trực tiếp từ NASA POWER API, **không được chỉnh sửa** sau khi thu thập. Đây là nguồn gốc duy nhất — mọi bước xử lý tiếp theo đều đọc từ thư mục này.

2.1 Dataset 1 — NASA_Solar_Data_Collected.csv

- **Nguồn:** NASA POWER API (<https://power.larc.nasa.gov>)
- **Phạm vi:** 42 trạm solar tại Úc
- **Thời gian:** 01/01/2020 – 30/04/2022
- **Số bản ghi:** ~35,742 dòng

- **Đơn vị thời gian:** Theo ngày

Cột	Kiểu	Mô tả
Date	date	Ngày ghi nhận (YYYY-MM-DD)
Site_ID	string	Mã trạm (Site_1 ...Site_42)
Latitude	float	Vĩ độ
Longitude	float	Kinh độ
ALLSKY_SFC_SW_DWN	float	Bức xạ mặt trời toàn phần — W/m ²
CLRSKY_SFC_SW_DWN	float	Bức xạ khi trời quang — W/m ²
PRECTOTCORR	float	Lượng mưa đã hiệu chỉnh — mm/ngày
T2M	float	Nhiệt độ không khí ở 2m — °C

2.2 Dataset 2 — VN_Solar_NASA_Data_All_Provinces.csv

- **Nguồn:** NASA POWER API + ArcGIS Geocoder
- **Phạm vi:** 63 tỉnh thành Việt Nam
- **Thời gian:** 01/01/2021 – 31/12/2023
- **Số bản ghi:** ~68,985 dòng
- **Đơn vị thời gian:** Theo ngày

Cột	Kiểu	Mô tả
Date	date	Ngày ghi nhận (YYYY-MM-DD)
SiteKey	string	Mã tỉnh (VN_PROVINCE_1 ...63)
PlantName	string	Tên tỉnh thành
Latitude	float	Vĩ độ
Longitude	float	Kinh độ
ALLSKY_SFC_SW_DWN	float	Bức xạ mặt trời toàn phần — W/m ²
CLRSKY_SFC_SW_DWN	float	Bức xạ khi trời quang — W/m ²
PRECTOTCORR	float	Lượng mưa đã hiệu chỉnh — mm/ngày
T2M	float	Nhiệt độ không khí ở 2m — °C

3 Thư mục processed/

Chứa dữ liệu đã qua bước làm sạch và chuẩn hóa từ raw/. Dữ liệu trong thư mục này sẵn sàng để dùng cho modeling và phân tích.

Các bước xử lý dữ kiện:

- Xử lý giá trị thiếu (NaN, -999 là giá trị lỗi của NASA POWER).
- Chuẩn hóa định dạng ngày tháng và kiểu dữ liệu.
- Loại bỏ bản ghi trùng lặp.
- Merge dữ liệu Úc và Việt Nam nếu cần train chung.

Trạng thái: Chờ bước ETL hoàn thành.

4 Thư mục `etl/`

Chứa các file trung gian sinh ra trong quá trình ETL (Extract – Transform – Load), bao gồm:

- File log ghi lại kết quả validation từng bước.
- File dữ liệu sau từng bước transform riêng lẻ (nếu cần debug).
- Script ETL hoặc notebook dùng để chạy pipeline.

Thư mục này không chứa dữ liệu cuối cùng — đó là vai trò của `processed/`.

5 Thư mục `doc/`

Chứa toàn bộ tài liệu mô tả dữ liệu, được chia thành 3 thư mục con.

5.1 `doc/schema/`

Mô tả cấu trúc bảng và quan hệ giữa các bảng dữ liệu. Bao gồm:

- Sơ đồ ERD (Entity Relationship Diagram) của kho dữ liệu.
- Định nghĩa kiểu dữ liệu, ràng buộc, khóa chính và khóa ngoại.
- Phiên bản schema theo từng giai đoạn cập nhật.

5.2 `doc/source_description/`

Mô tả nguồn gốc của từng bộ dữ liệu. Bao gồm:

- Tên và URL nguồn dữ liệu (NASA POWER API, ArcGIS).
- Phương thức thu thập: API crawl, tần suất cập nhật.
- Phạm vi địa lý và thời gian của từng dataset.
- Hạn chế và lưu ý khi sử dụng (rate limit, giá trị -999).

5.3 `doc/data_dictionary/`

Từ điển dữ liệu giải thích ý nghĩa từng cột trong các file CSV. Bao gồm:

- Tên cột, kiểu dữ liệu, đơn vị đo lường.
- Mô tả chi tiết ý nghĩa vật lý của từng chỉ số khí tượng.
- Khoảng giá trị hợp lệ và cách xử lý giá trị ngoại lệ.

6 Nguyên tắc quản lý dữ liệu

1. **Bất biến:** Dữ liệu trong raw/ không được sửa đổi sau khi thu thập. Mọi thay đổi phải thực hiện ở tầng processed/.
2. **Truy vết:** Mỗi file trong processed/ phải có thể truy ngược về file raw/ tương ứng.
3. **Tài liệu hóa:** Mọi thay đổi schema hoặc thêm nguồn dữ liệu mới phải cập nhật doc/.
4. **Không commit dữ liệu:** Thư mục data/ được thêm vào .gitignore, dữ liệu chỉ lưu trên Google Drive.

7 Kết luận

Cấu trúc thư mục trên Google Drive được thiết kế theo nguyên tắc phân tầng rõ ràng: dữ liệu thô (raw) → xử lý trung gian (etl) → dữ liệu sạch (processed), kèm tài liệu mô tả đầy đủ trong doc. Cách tổ chức này giúp nhóm dễ dàng cộng tác, truy vết nguồn gốc dữ liệu và mở rộng thêm dataset trong các sprint tiếp theo.